

VERİ GÖRSELLEŐTİRME

1. Giriő

Bu rapor, veri görselleőtirme projelerinde kullanılacak temel Python kütüphanelerini tanıtmak, seçilen grafik türlerinin avantaj ve dezavantajlarını incelemek ve kullanım senaryolarını belirlemek amacıyla hazırlanmıştır

2. Kütüphaneler

Veri görselleőtirme sürecinde aőağıdaki kütüphaneler kullanılacaktır:

A. Matplotlib (& Pyplot) – "Mühendis"

Python'ın en köklü görselleőtirme kütüphanesidir. `pyplot` modülü ile MATLAB benzeri bir deneyim sunar.

- **Avantajı:** Grafiğin her bir pikseli (eksenler, çizgiler, etiketler) üzerinde tam kontrol sağlar.
- **Dezavantajı:** Basit bir grafik için bile çok satır kod yazmak gerekebilir, varsayılan tasarımları biraz "eski moda" kalabilir.
- **Kullanım:** Akademik makaleler ve özelleştirilmiş statik grafikler için.

B. Seaborn – "Tasarımcı"

Matplotlib üzerine inşa edilmiş, istatistiksel görselleőtirmeler için optimize edilmiş bir kütüphanedir.

- **Avantajı:** Daha az kod ile göze hitap eden, modern ve renk uyumu yüksek grafikler çizer. Pandas veri çerçeveleriyle (DataFrames) mükemmel çalışır.
- **Dezavantajı:** Matplotlib kadar esnek değildir; çok spesifik özelleőtirmeler yapmak zorlaşabilir.
- **Kullanım:** Hızlı veri analizi (EDA) ve sunumlar için.

C. Plotly – "Sunucu"

İnteraktif (etkileşimli) grafikler oluőturan güçlü bir kütüphanedir.

- **Avantajı:** Grafiğin üzerine gelindiğinde (hover) detayların görünmesi, yakınlaőtırma (zoom) yapılabilmesi sayesinde dashboard'lar için idealdir.
- **Dezavantajı:** Statik raporlarda (PDF/kağıt baskı) interaktif özelliklerini kaybeder, dosya boyutları daha büyük olabilir.
- **Kullanım:** Web tabanlı raporlar ve yönetim sunumları için.

3. Grafik Türleri

Dokümanda belirtilen 5 temel grafik türü aőağıda detaylandırılmıştır:

A. Violin Plot (Keman Grafiği)

Kutu grafiği (Box Plot) ile Çekirdek Yoğunluk Tahmini'nin (KDE) birleşimidir.

- **Kullanım Amacı:** Verinin dağılım şeklini ve yoğunluğunu görmek.
- **Avantajları:**
 - ✓ Box Plot'tan daha fazla bilgi taşır; verinin nerede yoğunlaştığını (tepe noktalarını) gösterir.
 - ✓ Multimodal (çok tepeli) dağılımları tespit etmek için mükemmeldir.
- **Dezavantajları:**
 - ✓ İstatistiksel okuryazarlığı olmayan kişiler için okuması ve yorumlaması zordur.
 - ✓ Küçük veri setlerinde yanıltıcı şekiller oluşturabilir.

B. Box Plot (Kutu Grafiği)

Verinin istatistiksel özetini (min, Q1, medyan, Q3, max) gösteren standart grafik türüdür.

- **Kullanım Amacı:** Aykırı değerleri (outliers) yakalamak ve grupları kıyaslamak.
- **Avantajları:**
 - ✓ Büyük veri setlerinde bile az yer kaplayarak net bir özet sunar.
 - ✓ Aykırı değerleri (noktalar halinde) net bir şekilde ifşa eder.
- **Dezavantajları:**
 - ✓ Verinin dağılım şeklini (örneğin simetrik mi, çarpık mı) tam olarak göstermez; detayları gizler.

C. Line Chart (Çizgi Grafik)

Veri noktalarının zaman içindeki değişimini gösteren grafik türüdür.

- **Kullanım Amacı:** Trend analizi ve zaman serileri (Time-Series).
- **Avantajları:**
 - ✓ Artış, azalış ve mevsimsellik gibi trendleri görmek için en iyi yöntemdir.
 - ✓ Birden fazla grubun zaman içindeki performansını kıyaslamayı kolaylaştırır.
- **Dezavantajları:**
 - ✓ Çok fazla kategori (çizgi) eklendiğinde grafik okunamaz hale gelir ("Spaghetti Plot" sorunu).

D. Bar Chart (Sütun Grafik)

Kategorik verileri uzunluklarına göre temsil eder.

- **Kullanım Amacı:** Farklı gruplar arasındaki büyüklükleri karşılaştırmak.
- **Avantajları:**
 - ✓ Okunması ve anlaşılması en kolay grafik türüdür; genel izleyici kitlesine uygundur.
 - ✓ Hem dikey hem yatay kullanıma uygundur.
- **Dezavantajları:**
 - ✓ Kategori sayısı çok fazlaysa etiketler birbirine girer ve karmaşık görünür.

E. Pie Chart (Pasta Grafik)

Bir bütünün parçalarını oransal olarak gösterir.

- **Kullanım Amacı:** "Parça-Bütün" ilişkisini (yüzdeleri) göstermek.

- **Avantajları:**
 - ✓ Basit bir dağılımı (örn: Evet/Hayır) tek bakışta anlatır.
 - ✓ Estetik olarak raporlara renk katar.
- **Dezavantajları:**
 - ✓ İnsan gözü alanları/açıları kıyaslamakta zorlanır (Bar chart kadar net değildir).
 - ✓ 5'ten fazla dilim olduğunda veya dilimler birbirine yakın boyuttaysa okunması imkansızlaşır.

➤ Sonuç

Bu araştırma doğrultusunda, projenin Python aşamasında **Seaborn** (estetik analizler için) ve **Plotly** (detaylı inceleme için) ağırlıklı olarak kullanılacaktır. Her grafik türü için avantajlarına uygun, farklı veri setleri seçilerek görselleştirmeler yapılacaktır

4. Python Uygulama Aşaması

Dokümanda belirtilen kütüphaneler ve grafik türleri için uygun veri setleri seçilmiş ve Jupyter Notebook ortamında görselleştirme çalışmaları başlatılmıştır.

4.1 . Veri Seti Seçimi

İlk aşamada, kategorik ve sayısal verilerin dağılımını incelemek amacıyla Kaggle platformundan "**Students Performance in Exams**" veri seti tercih edilmiştir.

- **İçerik:** Öğrencilerin matematik, okuma ve yazma notları ile cinsiyet, ebeveyn eğitim durumu gibi demografik bilgilerini içerir.
- **Kullanım Amacı:** Farklı grupların başarı dağılımlarını kıyaslamak (Violin Plot) ve notlardaki sapmaları tespit etmek (Box Plot).
- Resim1' de ilk 5 verisi gösterilmiştir

```
In [1]: 1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4
5 sns.set(style="whitegrid")
6
7 df = pd.read_csv('StudentsPerformance.csv')
8 df.head()
```

```
Out[1]:
```

	gender	race/ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
0	female	group B	bachelor's degree	standard	none	72	72	74
1	female	group C	some college	standard	completed	69	90	88
2	female	group B	master's degree	standard	none	90	95	93
3	male	group A	associate's degree	free/reduced	none	47	57	44
4	male	group C	some college	standard	none	76	78	75

Resim 1 Students Performance in Exams Veri Setini İlk 5 Verisi

4.1.1. Grafik Uygulamaları ve Analizler


A. Box Plot



Şekil 1 Box Plot ile Matematik notlarının dağılımı ve uç değerler

Matematik notlarının dağılımını incelemek amacıyla Box Plot grafiği kullanılmıştır. Grafik, notların medyan değerini, çeyrekler arası aralığını ve uç değerleri göstermektedir. Matematik notlarının büyük bir bölümünün orta değerler etrafında toplandığı görülmektedir.


B. Violin Plot



Şekil 2 Violin Plot ile Cinsiyete göre matematik notlarının yoğunluğu

Cinsiyete göre matematik notlarının dağılımını ve yoğunluğunu incelemek amacıyla Violin Plot grafiği oluşturulmuştur. Grafik, her iki cinsiyet için notların dağılım yapısını karşılaştırmalı olarak göstermektedir.

C. Bar Chart




Şekil 3 Bar Chart ile Ebeveyn eğitim durumuna göre ortalama matematik notu

Ebeveyn eğitim durumuna göre öğrencilerin ortalama matematik notlarını karşılaştırmak amacıyla Bar Chart grafiği kullanılmıştır. Grafik, ebeveyn eğitim düzeyi ile akademik başarı arasındaki ilişkiyi ortaya koymaktadır.

D. Pie Chart

Gender Distribution of Students



Şekil 4 Pie Chart ile Öğrencilerin cinsiyet dağılımı

Öğrencilerin cinsiyet dağılımını göstermek amacıyla Pie Chart grafiği oluşturulmuştur. Grafik, veri setindeki kadın ve erkek öğrenci oranlarını oransal olarak sunmaktadır.


!!! Line Chart (çizgi grafiği), **zamana bağlı değişimlerin** veya sıralı veri yapılarının analiz edilmesi için kullanılan bir görselleştirme yöntemidir. Ancak bu çalışmada kullanılan *Students Performance in Exams* veri seti, **zaman serisi içermemekte** ve gözlemler arasında doğal bir zamansal sıralama bulunmamaktadır.

Bu nedenle, veri yapısına uygun olmayan bir görselleştirme yöntemi kullanmamak adına Line Chart grafiği tercih edilmemiştir. Çalışma kapsamında, veri setinin özelliklerine daha uygun olan **Box Plot, Violin Plot, Bar Chart ve Pie Chart** grafik türleri kullanılarak analizler gerçekleştirilmiştir.

4.1.2. Knime İle Veri Görselleştirme

Bu aşamada *Students Performance* veri seti, **KNIME Analytics Platform** kullanılarak görselleştirilmiştir. Veri seti, **CSV Reader** node'u ile okunmuş ve aynı veri kaynağı üzerinden farklı grafik türleri oluşturulmuştur. Öğrencilerin başarı dağılımlarını ve veri yapısını incelemek amacıyla **Box Plot**, **Histogram**, **Bar Chart** ve **Pie Chart** grafiklerinden yararlanılmıştır.

Oluşturulan görselleştirmeler sayesinde öğrencilerin sınav notlarının dağılımı, kategorik değişkenlere göre karşılaştırmaları ve genel veri yapısı açık ve anlaşılır bir şekilde analiz edilmiştir.



Şekil 5 'StudentsPerformance' Veri Setinin Knime ile Görselleştirilmesi

Şekil 5. *Students Performance* veri setinin KNIME Analytics Platform kullanılarak farklı grafik türleri ile görselleştirilmesi.

- **Pie Chart – Cinsiyet Dağılımı**

Pie Chart grafiği, öğrencilerin cinsiyete göre dağılımını göstermek amacıyla oluşturulmuştur. Grafik incelendiğinde, veri setinde yer alan öğrencilerin **%51,8’inin kadın, %48,2’sinin erkek** olduğu görülmektedir. Bu durum, veri setinde cinsiyet dağılımının dengeli olduğunu göstermektedir.


Pie Chart



Şekil 6 Öğrencilerin cinsiyete göre dağılımını gösteren Pie Chart grafiği.

- **Box Plot – Sınav Notlarının Dağılımı**


Box Plot grafiğı kullanılarak matematik, okuma ve yazma notlarının dağılımları karşılaştırmalı olarak incelenmiştir. Grafikler, sınav notlarının medyan değerlerini, çeyrekler arası aralıklarını ve uç değerlerini açık bir şekilde göstermektedir. Okuma ve yazma notlarının medyan değerlerinin matematik notlarına kıyasla daha yüksek olduğu gözlemlenmiştir.



Şekil 7 Matematik, okuma ve yazma notlarının Box Plot grafiğı.

- **Bar Chart – Ebeveyn Eğitim Düzeyi Dağılımı**

Bar Chart grafiği, öğrencilerin ebeveyn eğitim düzeylerinin veri setindeki dağılımını göstermek amacıyla kullanılmıştır. Grafik incelendiğinde, “**some college**” ve “**associate’s degree**” kategorilerinin daha yüksek frekansa sahip olduğu görülmektedir. Bu görselleştirme, kategorik verilerin karşılaştırılması açısından etkili bir sonuç sunmaktadır.




Şekil 8 Ebeveyn eğitim düzeylerinin Bar Chart grafiği.

- **Histogram – Matematik Notlarının Genel Dağılımı**

Histogram grafiđi, öğrencilerin matematik notlarının genel dağılımını incelemek amacıyla oluşturulmuştur. Grafik, matematik notlarının büyük oranda **60–80 puan aralığında yoğunlaştığını** ve dağılımın yaklaşık normal bir yapı sergilediğini göstermektedir. Histogram, Box Plot grafiđini tamamlayıcı nitelikte bir analiz sunmaktadır.

Histogram



Şekil 9 Matematik notlarının Histogram grafiđi.

Genel Değerlendirme

KNIME Analytics Platform kullanılarak elde edilen bu görselleştirmeler sayesinde veri setinin hem demografik yapısı hem de akademik başarı dağılımları açık bir şekilde analiz edilmiştir. Kullanılan grafik türleri, veri yapısına uygun şekilde seçilmiş ve görsel analiz sürecini desteklemiştir.

4.2 Veri Seti Seçimi

Bu çalışmada kullanılan **monthly_csv** veri seti, aylık bazda toplanmış ölçümleri içermektedir. Veri setinin genel yapısını ve değişkenlerini incelemek amacıyla ilk beş gözlem satırı görüntülenmiştir.

İlk beş gözlem üzerinden, veri setinde yer alan sütunlar, tarih bilgileri ve sayısal değerlerin yapısı incelenmiş; görselleştirme aşamasında kullanılacak değişkenler belirlenmiştir.


Şekil 10 'da monthly_csv veri setine ait ilk 5 gözlem sunulmuştur.

	Source	Date	Mean
0	GCAG	2016-12-06	0.7895
1	GISTEMP	2016-12-06	0.8100
2	GCAG	2016-11-06	0.7504
3	GISTEMP	2016-11-06	0.9300
4	GCAG	2016-10-06	0.7292

Şekil 10 monthly_csv veri setine ait ilk beş gözlemin Jupyter Notebook ortamında görüntülenmesi.

- LINE CHART


Aylık ortalama sıcaklık anomalilerinin zamana bağlı değişimini incelemek amacıyla Line Chart grafiği kullanılmıştır. Grafik, farklı veri kaynaklarının (GCAG ve GISTEMP) zaman içerisindeki eğilimlerini karşılaştırmalı olarak göstermektedir.



Şekil 11 Aylara göre değerlerin değişimini gösteren Line Chart grafiği.

- BAR CHART


Farklı veri kaynaklarına ait ortalama sıcaklık anomalilerini karşılaştırmak amacıyla Bar Chart grafiğı kullanılmıştır. Grafik, GCAG ve GISTEMP kaynakları arasında küçük farklılıklar bulunduğunu göstermektedir.



Şekil 12 Veri kaynaklarına göre ortalama sıcaklık anomalileri.

- BOX PLOT


Box Plot grafiđi, veri kaynaklarına göre ortalama sıcaklık anomalilerinin dađılımını ve olası uç deđerleri göstermektedir. Grafik, kaynaklar arasındaki dađılım benzerliklerini ve farklılıklarını ortaya koymaktadır.



Şekil 13 Veri kaynaklarına göre ortalama deđerlerin Box Plot grafiđi.

- VIOLIN PLOT

Violin Plot grafiđi, veri kaynaklarına göre sıcaklık anomalilerinin dađılımlarını ve yoğunluk yapılarını birlikte göstermektedir. Grafik, Box Plot'a ek olarak veri yoğunluđu hakkında daha ayrıntılı bilgi sunmaktadır.




Şekil 14 Veri kaynaklarına göre ortalama deđerlerin Violin Plot grafiđi

4.2.2 Knime İle Veri Görselleştirme

Bu aşamada *monthly_csv* veri seti, **KNIME Analytics Platform** kullanılarak görselleştirilmiştir. Veri seti, **CSV Reader** node'u ile okunmuş ve aynı veri kaynağı üzerinden farklı grafik türleri oluşturulmuştur. Öğrencilerin başarı dağılımlarını ve veri yapısını incelemek amacıyla **Line Chart**, **Box Plot** ve **Pie Chart** grafiklerinden yararlanılmıştır.


Oluşturulan görselleştirmeler sayesinde öğrencilerin sınav notlarının dağılımı, kategorik değişkenlere göre karşılaştırmaları ve genel veri yapısı açık ve anlaşılır bir şekilde analiz edilmiştir.



Şekil 15 *monthly_csv* Veri Setinin Knime ile Görselleştirilmesi

- LINE PLOT


Aylık ortalama sıcaklık anomalilerinin zamana bağılı deęişimini incelemek amacıyla Line Plot grafięi kullanılmıştır. Grafik, GCAG ve GISTEMP veri kaynaklarının zaman içerisindeki eğilimlerini karşılaştırmalı olarak göstermektedir.



Şekil 16 Aylık ortalama sıcaklık anomalilerinin zamana göre deęişimi

- BAR CHART


Bar Chart grafiđi, farklı veri kaynaklarına ait ortalama sıcaklık anomalilerini karşılaştırmak amacıyla oluşturulmuştur. Grafik, GCAG ve GISTEMP kaynakları arasındaki ortalama değeri farklarını göstermektedir.



Şekil 17 Veri kaynaklarına göre ortalama değeri farkların Bar Chart grafiđi

- Box Plot

Box Plot grafiđi, veri kaynaklarına göre ortalama deđerlerin dađılımını, medyanlarını ve olası uç deđerleri göstermektedir. Grafik, kaynaklar arasındaki dađılım farklılıklarını analiz etmeye olanak sađlamaktadır.




Şekil 18 Veri kaynaklarına göre ortalama deđerlerin Box Plot grafiđi

- Pie Chart

Pie Chart grafiđi, veri setinde yer alan kaynakların oransal dağılımını göstermek amacıyla oluşturulmuştur.

Pie Chart



Şekil 19 Veri kaynaklarının oransal dağılımı.

Genel Sonuç ve Değerlendirme

Bu çalışma kapsamında, farklı yapısal özelliklere sahip iki ayrı veri seti üzerinde veri görselleştirme yöntemleri uygulanmıştır. İlk veri seti olan *Students Performance in Exams*, öğrencilerin akademik başarıları ve demografik bilgilerini içeren **kesitsel (cross-sectional)** bir yapıya sahiptir. İkinci veri seti olan *monthly_csv* ise aylık bazda ölçülmüş ortalama değerleri içeren **zaman serisi** yapısındadır. Bu farklılıklar, her veri seti için uygun görselleştirme tekniklerinin seçilmesini gerekli kılmıştır.

Students Performance veri seti üzerinde yapılan analizlerde, **Box Plot** ve **Violin Plot** grafikleri ile sınav notlarının dağılımları, medyan değerleri ve aykırı gözlemler incelenmiştir. **Bar Chart** ve **Pie Chart** grafikleri ise öğrencilerin demografik özelliklerinin ve kategorik değişkenlerin dağılımını görsel olarak karşılaştırmaya olanak sağlamıştır. Bu görselleştirmeler sayesinde öğrencilerin başarı düzeylerinin belirli aralıklarda yoğunlaştığı ve veri setinde dengeli bir demografik yapı bulunduğu gözlemlenmiştir. Zaman serisi içermemesi nedeniyle bu veri seti için Line Chart kullanılmamış ve bu durum veri yapısına uygun bir tercih olarak değerlendirilmiştir.

monthly_csv veri seti üzerinde gerçekleştirilen analizlerde ise zamana bağlı değişimleri ortaya koymak amacıyla **Line Chart** grafiği temel görselleştirme aracı olarak kullanılmıştır. Grafikler, farklı veri kaynaklarının zaman içerisindeki eğilimlerini karşılaştırmalı olarak incelemeye olanak sağlamıştır. **Bar Chart**, **Box Plot**, **Violin Plot** ve **Histogram** grafikleri ile değerlerin ortalama düzeyleri, dağılımları ve yoğunluk yapıları analiz edilmiştir. **Pie Chart** ise veri kaynaklarının oransal dağılımını destekleyici bir görselleştirme olarak kullanılmıştır.

Her iki veri seti için de görselleştirme süreci, veri yapısına uygun grafik türlerinin seçilmesinin analiz kalitesini doğrudan etkilediğini göstermiştir. **Jupyter Notebook** ve **KNIME Analytics Platform** ortamlarında elde edilen sonuçlar birbiriyle tutarlı olup, kullanılan araçların veri keşfi ve yorumlama süreçlerinde etkili olduğu görülmüştür. Sonuç olarak, bu çalışma veri görselleştirmenin hem kesitsel hem de zaman serisi verilerinde, verinin anlaşılabilirliğini artıran önemli bir analiz yöntemi olduğunu ortaya koymaktadır.